

Pencarian Resep Makanan Sehat Menggunakan *Hybrid Model BM25L dan MiniLM*

Shiba Salsabilla, Rashiqa Dewi Nariswari, Nabila Dien Jasmine, Hafidz Rizky Effendi, Putu Angga Kurniawan, Naufal Afif

Abstract

Background: Kesadaran masyarakat terhadap pola makan sehat terus meningkat, sehingga mendorong kebutuhan akan sistem pencarian resep makanan sehat yang mampu memberikan hasil pencarian yang relevan dan berkualitas. Namun, sistem *information retrieval* tradisional seringkali menghadapi kendala dalam memahami konteks dan relevansi semantik dari permintaan pengguna, yang mengakibatkan hasil pencarian kurang optimal. Oleh karena itu, pendekatan baru diperlukan untuk menjawab tantangan ini.

Objective: Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi model hibrida yang mengintegrasikan algoritma BM25L untuk pencarian berbasis kata kunci dengan MiniLM untuk pemahaman konteks semantik. Pendekatan ini diharapkan mampu meningkatkan kualitas dan relevansi hasil pencarian dalam sistem pencarian resep makanan sehat.

Methods: Metodologi penelitian mencakup beberapa tahapan, yaitu (1) pengumpulan dataset dari platform EatingWell melalui proses web scraping yang mencakup berbagai resep makanan sehat, (2) pra-pemrosesan data untuk memastikan kualitas dan konsistensi dataset, (3) penerapan algoritma BM25L sebagai metode pencarian berbasis kata kunci untuk menghitung relevansi secara leksikal, (4) penerapan MiniLM sebagai metode analisis semantik untuk memahami konteks dokumen, (5) penggabungan skor relevansi dari kedua model menggunakan teknik hybrid berbasis Reciprocal Rank Fusion (RRF), (6) evaluasi performa model menggunakan metrik precision dan recall untuk menentukan model terbaik, dan (7) fine-tuning model terbaik untuk meningkatkan performanya sebelum dijadikan sebagai model akhir yang diusulkan.

Results: Hasil eksperimen menunjukkan bahwa model BM25L unggul dalam precision dengan skor p5 sebesar 0.380 dibandingkan metode lainnya, tetapi memiliki kelemahan pada recall, terlihat dari r5 sebesar 0.192. Di sisi lain, metode semantic berbasis Ontology menunjukkan kemampuan menangkap variasi dokumen relevan dengan skor recall r5 sebesar 0.105, tetapi precision-nya lebih rendah dibandingkan BM25L. Model hybrid, seperti BM25L & Ontology dan BM25L & MiniLM, mampu meningkatkan keseimbangan antara precision dan recall, dengan rata-rata p20 masing-masing sebesar 0.274 dan 0.310, serta r20 sebesar 0.169 dan 0.180. Selain itu, model terbaik BM25L & MiniLM menunjukkan peningkatan kinerja setelah dilakukan fine-tuning, dengan skor p20 meningkat dari 0.310 menjadi 0.324 dan r20 meningkat dari 0.180 menjadi 0.193. Hal ini menunjukkan bahwa fine-tuning dapat secara efektif meningkatkan performa model hybrid.

Conclusion: Penelitian ini menunjukkan bahwa pendekatan hybrid yang mengintegrasikan algoritma BM25L untuk pencarian berbasis kata kunci dan MiniLM untuk pemahaman semantik mampu meningkatkan relevansi dan kualitas hasil pencarian dalam sistem pencarian resep makanan sehat. Model hybrid BM25L & MiniLM menunjukkan performa terbaik dengan keseimbangan antara precision dan recall, yang semakin meningkat setelah dilakukan fine-tuning. Pendekatan ini berhasil mengatasi kelemahan dari model individual, seperti BM25L yang unggul dalam precision tetapi lemah pada recall, dan pendekatan semantik yang kuat dalam recall tetapi rendah pada precision. Hasil ini mengindikasikan bahwa kombinasi model berbasis kata kunci dan semantik melalui teknik Reciprocal Rank Fusion (RRF) adalah strategi efektif untuk menghasilkan sistem pencarian yang lebih relevan dan berkualitas tinggi.

Keywords: *Information Retrieval, BM25, MiniLM, Resep Makanan Sehat, Hybrid Model*

Introduction

Seiring dengan kemajuan penelitian *Natural Language Processing* (NLP), berbagai model berhasil dikembangkan untuk memenuhi tujuan utama NLP, yaitu mengolah data tekstual agar bahasa alami dapat diinterpretasikan oleh mesin untuk mendukung efisiensi proses penggalian wawasan atau makna dari teks (Khurana *et al.*, 2023). *Information Retrieval* atau IR merupakan irisan dari *Natural Language Processing* sebagai impresi dari kemajuan penelitian

dan kebutuhan di bidang ini. *Information Retrieval* didefinisikan sebagai proses menemukan informasi relevan dari sekumpulan data yang besar, terutama dalam bentuk teks, untuk menjawab pertanyaan atau kebutuhan pengguna secara efisien. Menurut Zhu *et al* pada tahun 2023, fungsi inti dari sistem ini adalah penambangan informasi untuk menentukan relevansi antara *kueri* yang diinginkan *user* terhadap konten yang dapat berupa informasi, teks, gambar, musik, dan lainnya (Zhu *et al.*, 2023). *Information Retrieval* akan mengembalikan hasil yang paling sesuai dengan kebutuhan *user* berdasarkan analisis data yang tersedia. Kemampuan ini menjadi komponen penting dalam mendukung efisiensi pencarian dan pengambilan informasi di era data yang terus berkembang.

Information Retrieval telah diimplementasikan dalam pencarian informasi di berbagai aspek. Aspek tersebut meliputi kesehatan (Agrawal *et al.*, 2022; Yu *et al.*, 2023; Ciampi *et al.*, 2020), *web search* (Wang *et al.*, 2023; C *et al.*, 2020), hukum (Sansone & Sperli, 2022), pencarian dokumen tertentu (Saxena *et al.*, 2022; Yang *et al.*, 2024), dan sebagainya. Sistem ini juga diimplementasikan dalam sistem dialog seperti Microsoft Xiaoice, Apple Siri, dan Google Assistant untuk menghasilkan respons yang tepat sesuai dengan input pengguna. Hal ini mendukung adanya percakapan yang lebih alami antara manusia dan mesin. Terdapat berbagai pendekatan yang digunakan untuk mengembangkan sistem *Information Retrieval*. Hal ini merujuk pada metode dan teknik yang terdefinisi menjadi beberapa kategori yaitu *Boolean Retrieval*, *Vector Space Model* (VSM), dan *Probabilistic Retrieval Model*. Setiap pendekatan memiliki keunggulan dan kelemahan yang sesuai dengan kebutuhan sistem pencarian informasi. *Boolean Retrieval* cocok untuk pencarian dengan aturan logika yang sederhana. Berbeda dengan *Boolean Retrieval*, VSM mendukung fleksibilitas dalam mengukur relevansi berdasarkan kesamaan vektor (Kalmukov, 2022). Sementara itu, *Probabilistic Retrieval Model* unggul dalam menangani ketidakpastian *kueri* pengguna dengan menggunakan pendekatan berbasis probabilitas untuk menghasilkan hasil yang lebih relevan (Guo *et al.*, 2022).

Pendekatan dan model *Information Retrieval* yang bervariasi dirancang secara fleksibel untuk memenuhi kebutuhan *user*. Dalam bidang gizi dan kesehatan, teknologi ini dapat dimanfaatkan untuk menyediakan informasi *diet* yang relevan sesuai dengan kebutuhan nutrisi, preferensi makanan, jenis pengolahan, atau kondisi kesehatan individu. Hal ini menjadi urgensi seiring dengan meningkatnya prevalensi obesitas dan penyakit kronis akibat pola makan yang tidak sehat. *Information Retrieval* dapat membantu *decision making* pada *user* dalam konteks pemilihan makanan yang sesuai dengan kebutuhan *diet*-nya. Namun, tantangan yang dihadapi mencakup variasi preferensi makanan, kebutuhan nutrisi yang berbeda-beda untuk setiap individu, serta keterbatasan dalam mendapatkan informasi yang tepat dan sesuai.

Dalam beberapa dekade terakhir, tantangan dalam pengelolaan diet yang sehat dan berkelanjutan semakin meningkat seiring dengan berbagai krisis global, termasuk perubahan iklim, masalah kesehatan, dan tekanan sosial-ekonomi. Pola konsumsi makanan yang tidak sehat telah menjadi kontributor utama terhadap meningkatnya prevalensi obesitas dan penyakit tidak menular seperti diabetes dan penyakit kardiovaskular, sementara ketidaksetaraan akses terhadap makanan sehat memperburuk disparitas kesehatan di banyak masyarakat (Spiro *et al.*, 2024). Selain itu, keberlanjutan makanan juga dipengaruhi oleh tingginya jejak ekologis dari sistem produksi pangan, yang menyumbang 19–37% dari emisi gas rumah kaca global (Varela, 2024). Di sisi lain, meskipun penelitian menunjukkan potensi diet berbasis tumbuhan seperti Diet Mediterania dan pengenalan bahan makanan inovatif seperti Moringa oleifera, kendala dalam memahami hubungan kompleks antara komposisi makanan, metabolisme, dan kesehatan individu masih menjadi tantangan besar dalam penerapan pola makan yang optimal dan berkelanjutan (Picone *et al.*, 2024; Xie *et al.*, 2024).

Information Retrieval berperan dalam meningkatkan aksesibilitas informasi diet yang relevan untuk masyarakat umum dan profesional kesehatan. Sistem ini bertujuan untuk membantu *user* dalam menemukan resep yang sesuai dengan kebutuhan nutrisi dan kondisi kesehatan. Dalam proyek ini, akan dikembangkan model *Information Retrieval* yang untuk memahami dan menjawab *kueri* pengguna terkait kebutuhan diet. Model yang dikembangkan ini mengintegrasikan data resep, kategori diet, instruksi, dan informasi nutrisi untuk memberikan rekomendasi yang dipersonalisasi. Dengan pendekatan ini, diharapkan sistem dapat membantu pengguna membuat keputusan yang lebih baik terkait pola makan. Proyek ini juga bertujuan untuk meningkatkan kualitas hidup masyarakat melalui akses informasi yang lebih mudah dan relevan.

Related Works

Penelitian dalam *information retrieval* (IR) telah berkembang dengan munculnya pendekatan berbasis leksikal, semantik, dan *hybrid*. Tantangan utama IR terletak pada kesenjangan semantik dan perbedaan kosakata antar pengguna, seperti pertanyaan umum maupun spesifik. Pada penelitian sebelumnya yang dilakukan Maryamah *et al.* (2024) mengacu pada masalah kompleksitas bahasa medis yang sering kali mengandung akronim, variasi ejaan, dan tafsiran yang ambigu. Untuk mengatasi kendala tersebut, pendekatan semantik berbasis embedding, seperti BERT dan MPNet, dilakukan. Model leksikal seperti BM25L mampu mempertahankan *precision* yang tinggi melalui perhitungan berbasis frekuensi kata, meskipun cenderung kurang adaptif terhadap semantik. Metode *hybrid* yang menggabungkan model leksikal dan semantik meningkatkan kualitas pencarian. Kombinasi BM25L dan MPNet melalui algoritma *Reciprocal Rank Fusion* terbukti meningkatkan *recall* dan *precision*, terutama dalam *kueri* kompleks. Pendekatan ini menunjukkan potensi untuk diterapkan pada bidang lainnya seperti pencarian resep makanan, yang juga menghadapi tantangan serupa, termasuk variasi istilah bahan makanan, teknik memasak, dan gaya penulisan resep.

Dalam penelitian pencarian resep makanan sehat, penerapan model *hybrid* dapat mengatasi berbagai tantangan tersebut. Model seperti Sentence-BERT mampu memahami hubungan semantik antara kata-kata dalam *kueri* dan dokumen, sehingga meningkatkan relevansi pencarian (Walsh & Andrade, 2022; Kim *et al.*, 2022). Sementara itu, BM25L yang berbasis frekuensi kata tetap dapat memberikan performa yang solid dalam memahami istilah-istilah yang bersifat langsung dan spesifik. Integrasi kedua metode ini memanfaatkan kekuatan masing-masing untuk mendukung pencarian yang lebih akurat dan responsif terhadap permintaan pengguna yang beragam. Penelitian terkait seperti oleh Wang *et al* menunjukkan bagaimana model berbasis embedding dapat mengidentifikasi dan menggabungkan informasi yang relevan dalam skala yang lebih besar, memperluas potensi *hybrid* model untuk digunakan dalam aplikasi yang memerlukan pemahaman semantik yang lebih dalam.

Dalam pengembangan *information retrieval* untuk resep *diet*, beberapa literatur telah ditemukan. Pengembangan sistem *information retrieval* untuk resep diet telah didukung oleh berbagai penelitian dari waktu ke waktu. Pada tahun 2020, Chen *et al.* mengusulkan sistem rekomendasi resep yang berfokus pada eksplorasi informasi nutrisi untuk mendorong kebiasaan makan yang lebih sehat (Chen *et al.*, 2020). Zan *et al.* memperkenalkan metode cross-modal retrieval yang tahan gangguan untuk menghubungkan gambar makanan dengan resep berbasis teks dan sebaliknya (Zan *et al.*, 2020). Di tahun yang sama, Wang *et al.* mengembangkan Market2Dish, sebuah sistem rekomendasi makanan yang memperhatikan aspek kesehatan dengan menghubungkan bahan-bahan yang tersedia di pasar dengan resep yang sesuai (Wang *et*

al., 2020). Pada tahun 2021, Li *et al.* memperkenalkan metode pencarian resep berbasis nutrisi menggunakan *pre-trained recipe embeddings* yang mendukung pencarian lebih efisien dan relevan (Li *et al.*, 2021). Tahun berikutnya, yaitu 2022, Pallagani *et al.* menyajikan pendekatan variatif untuk representasi resep guna mendukung kueri multi-modal yang ekspresif, mencakup konten dan proses persiapan resep (Pallagani *et al.*, 2022). Pada tahun 2024, Palermo *et al.* mengusulkan sistem rekomendasi berbasis *food pairing* untuk memahami dinamika penciptaan resep, sementara Yang *et al.* memperkenalkan ChatDiet, sebuah *chatbot* yang dipersonalisasi untuk mendukung rekomendasi makanan berbasis nutrisi (Palermo *et al.*, 20204; Yang *et al.*, 2024). Pada tahun yang sama, Zhang *et al.* mengembangkan metode rekomendasi makanan multimodal menggunakan teknik *clustering* dan *self-supervised learning* yang memanfaatkan data lintas-modalitas untuk meningkatkan akurasi dan personalisasi (Zhang *et al.*, 2024).

Penelitian-penelitian ini menunjukkan perkembangan signifikan dalam pendekatan dan teknologi yang digunakan untuk mendukung pencarian dan rekomendasi resep diet yang lebih relevan. Berdasarkan *preview* yang telah dideskripsikan, 8 penelitian *information retrieval* dalam konteks resep masakan yang berkorelasi dengan aspek nutrisi diekstrak dalam *literatur review* ini. *Keyword* yang digunakan adalah “*information retrieval*”, “*diet*”, “*recipe*”, “*meal*”, dan “*nutrition*.” Masing masing penelitian mengimplementasikan model yang berbeda. *Performance metrics* yang dihasilkan pun bervariasi.

Model dengan *precision* dan *recall* paling tinggi terdapat pada penelitian Wang *et al.* (2020). Penelitian ini mengimplementasikan beberapa model, yaitu FastText, EXAM, RCNN, TextCNN, HAN, WIRCINN. Hasil menunjukkan bahwa metode WIRCINN memiliki performa terbaik dengan nilai *precision* sebesar 98.11% dan *recall* sebesar 97.62% (Wang *et al.*, 2020). Metode ini mampu secara akurat mengidentifikasi data relevan sekaligus meminimalkan kesalahan deteksi. WIRCINN atau *Weighted Input Representation Convolutional Neural Network* didefinisikan sebagai sebuah metode *deep learning* yang dirancang untuk memproses data kompleks dengan mempertimbangkan bobot tertentu pada representasi *input*. Pendekatan ini sering digunakan untuk tugas-tugas klasifikasi atau prediksi yang melibatkan data tekstual, visual, atau kombinasi multimodal. Model ini memiliki performa paling baik diantara model yang diusulkan pada literatur lainnya.

Penelitian berikutnya dengan nilai *precision* dan *recall* tertinggi adalah Pallagani *et al.* (2022) dalam studi berjudul “*A Rich Recipe Representation as Plan to Support Expressive Multi-Modal Queries on Recipe Content and Preparation Process*”. Penelitian ini mengevaluasi berbagai pendekatan seperti Glove, Word2Vec, NumberBatch, dan Transformer. Secara keseluruhan, model Transformer menunjukkan performa terbaik dengan nilai *precision*, *recall*, dan F1-Score masing-masing sebesar 93% (Pallagani *et al.*, 2022). Hal ini menegaskan kapabilitas model Transformer dalam menangani data multimodal dan mendukung analisis yang lebih ekspresif terhadap konten dan proses persiapan resep. Model Transformer adalah arsitektur jaringan saraf dalam *deep learning* yang pertama kali diperkenalkan oleh Vaswani *et al.* pada tahun 2017 dalam paper berjudul “*Attention is All You Need*” (Vaswani *et al.*, 2017). Transformer dirancang untuk menangani *sequence* data seperti teks atau suara. *Attention* mechanism bekerja secara paralel, mempelajari urutan feedback dengan pendekatan terpusat, serta mengkodekan posisi tiap elemen dalam urutan tersebut (Huy *et al.*, 2022a). Maka dari itu, dibandingkan dengan RNN, model TFT lebih robust untuk menangani berbagai sumber dan jenis data, serta memiliki kapabilitas untuk meningkatkan interpretabilitas hasil prediksi (Hongwei *et al.*, 2023; Zheng *et al.*, 2023).

Penelitian oleh Yang *et al.* (2024) memperkenalkan ChatDiet dengan mengimplementasikan *Large Language Models* (LLM). Model ini mencapai akurasi sebesar

92%. Metrik lainnya seperti *precision* dan *recall* tidak disebutkan dalam studi ini (Yang *et al.*, 2024). Sementara itu, Palermo *et al.* (2024) melakukan *task information retrieval* menggunakan pendekatan *clustering*, yaitu K-Means, *hierarchical clustering*, serta LightGCN dalam sistem rekomendasi berbasis *food pairing*. Metode LightGCN terbukti unggul dalam hal mean Average Precision (mAP) sebesar 30% dan Hit Rate (HR) sebesar 70% (Palermo *et al.*, 2024). Penelitian oleh Chen *et al.* (2020) mengimplementasikan kombinasi pendekatan seperti IP-embedding, IP-graph, IP-MLP, dan IP-NMF. Di antara semua metode tersebut, IP-embedding terbukti menjadi model terbaik, dengan kemampuan memasukkan bahan yang benar dalam 10 opsi teratas sebesar 52,6% pada dataset Allrecipes, dan 51,9% pada dataset lainnya (Chen *et al.*, 2020).

Penelitian Zhang *et al.* (2024) berjudul "*Multi-modal Food Recommendation using Clustering and Self-supervised Learning*" menggabungkan beberapa teknik canggih untuk rekomendasi makanan berbasis data multi-modal. Mereka menggunakan LightGCN, Unimodal graph representation learning, cross-modal self-supervised learning (CLUSSL), dan multi-task learning. Dari berbagai metode yang diuji, CLUSSL menunjukkan performa terbaik dengan nilai recall sebesar 15,16% dan NDCG (*Normalized Discounted Cumulative Gain*) sebesar 12,62% (Zhang *et al.*, 2024). Penelitian lainnya, yaitu Li *et al.* (2021) berjudul "*Nutrition Guided Recipe Search via Pre-trained Recipe Embeddings*" menggunakan pre-trained embeddings untuk pencarian resep yang dipandu oleh informasi nutrisi. Pendekatan ini terbukti lebih efektif dibandingkan metode pencarian berbasis kata kunci, karena dapat memberikan variasi judul resep yang lebih luas dan relevan dengan preferensi nutrisi pengguna (Li *et al.*, 2021)). Di sisi lain, Zan *et al.* (2020) dalam studi "*Sentence-based and Noise-robust Cross-modal Retrieval on Cooking Recipes and Food Images*" mengaplikasikan BERT untuk embedding teks guna menghubungkan informasi semantik antara resep berbasis teks dan gambar makanan. Model ini mampu merepresentasikan informasi semantik secara efektif pada lima gambar teratas, memberikan hasil yang lebih akurat dalam pencarian yang melibatkan data teks dan visual (Zan *et al.*, 2020).

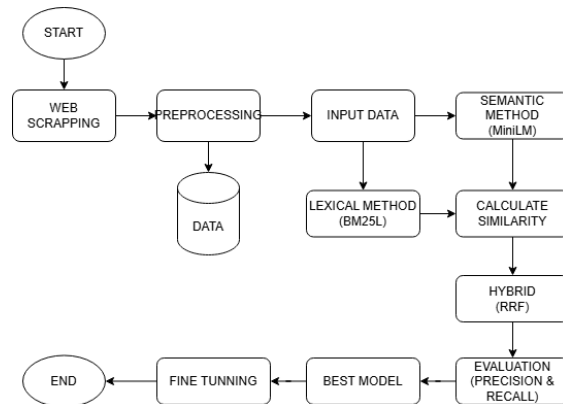
Methods

1. Material

Dataset yang digunakan dalam penelitian ini merupakan dataset primer yang diperoleh melalui metode *web scraping* dari situs *EatingWell*. *EatingWell* adalah platform yang menyediakan berbagai informasi mengenai resep makanan sehat, serta tips dan panduan gizi. Dataset ini terdiri dari 5.190 data resep makanan yang mencakup berbagai atribut, seperti tautan, judul artikel, nama penulis, rincian, deskripsi makanan, informasi, takaran nutrisi, jumlah penyajian, rating, kategori waktu makan, asal makanan, resep, dan instruksi. Data yang telah diekstraksi disimpan dalam format CSV untuk keperluan analisis lebih lanjut.

2. Metodologi

Subbab ini mencakup penjelasan tentang metode yang digunakan dalam penelitian, yang melibatkan pendekatan leksikal, semantik, dan hybrid.



Gambar 1. Rangkaian keseluruhan metode yang digunakan di penelitian ini.

Tahapan pertama dilakukan *web scraping* untuk mengambil data resep makanan dari *EatingWell*. *Preprocessing* seperti *lowercase*, menggunakan operasi *regex* untuk menghilangkan karakter yang tidak relevan, dan *lemmatization* untuk mengambil kata dasar dari dataset untuk menghindari kompleksitas komputasi. Selanjutnya untuk pemodelan dataset diuji satu persatu dengan metode *leksikal*, *semantik*, kemudian *hybrid*. Pada metode *leksikal*, kami menggunakan BM25L untuk menghitung relevansi berdasarkan frekuensi term dalam dokumen. BM25L dikenal efektif dalam menangani panjang dokumen yang berbeda-beda, serta memberikan bobot yang lebih pada kata-kata yang lebih penting untuk pencarian.

Kemudian, untuk metode *semantik*, kami menggunakan *Sentence Transformers*, sebuah model berbasis *transformer* yang mampu memahami konteks kata dalam kalimat, sehingga dapat menangkap hubungan semantik yang lebih mendalam antar kata dan frasa dalam resep makanan. Hasil akhir dari kedua metode ini akan dihitung nilai kesamaannya menggunakan teknik perhitungan *similarity* untuk menilai seberapa relevan dokumen terhadap kueri yang diberikan.

Setelah itu, hasil dari kedua metode tersebut digabungkan menggunakan *Reciprocal Rank Fusion (RRF)*. Metode ini bertujuan untuk memadukan hasil pencarian dari BM25L dan *Sentence Transformers* untuk mendapatkan hasil pencarian yang lebih optimal. Terakhir, performa dari ketiga model ini dievaluasi menggunakan metrik *precision* dan *recall* dengan dokumen yang diambil pada peringkat 5, 10, dan 20 untuk menguji sejauh mana model dapat memberikan hasil yang relevan sesuai dengan kueri yang diberikan. Evaluasi ini dilakukan menggunakan total 60 kueri yang beragam untuk memastikan keandalan dan efektivitas model dalam pencarian resep makanan.

a). Metode Leksikal

Metode leksikal merupakan pendekatan yang mengutamakan bagaimana kata-kata disusun dan terhubung, tanpa mempertimbangkan informasi atau makna lainnya (Yang *et al.*, 2024)). Metode ini berfokus pada pemrosesan kata dan perhitungan frekuensi kemunculan kata dalam koleksi dokumen. BM25L (Best Matching 25 with Length Normalization) adalah pengembangan dari algoritma BM25 yang mengatasi kekurangan dalam penanganan panjang dokumen dengan lebih baik. BM25L mengadaptasi fungsi BM25 dengan memasukkan parameter panjang dokumen yang lebih fleksibel sehingga lebih efektif dalam menilai relevansi dokumen dengan mempertimbangkan panjangnya. Algoritma ini dirancang untuk mengatasi kelemahan dalam penanganan dokumen panjang, di mana model standar BM25 cenderung memberikan penalti yang berlebihan terhadap dokumen yang lebih panjang (Santos *et al.*, 2024).

$$Score(D, Q) = \sum_{t \in Q} IDF(t) \cdot \frac{TF(t, D)(k_1 + 1)}{TF(t, D) + k_1(1 - b + \frac{|D|}{avgDL})}$$

Di mana:

$$IDF(t) = \log\left(\frac{N - n_t + 0,5}{n_t + 0,5}\right)$$

b). Metode Semantik

Metode semantik dalam pengambilan informasi bertujuan untuk memahami makna dan konteks teks, sehingga meningkatkan akurasi dalam pencarian informasi (Kim et al., 2022). Pendekatan ini melampaui metode leksikal tradisional yang hanya mengandalkan kecocokan eksplisit kata kunci, dengan memanfaatkan model pembelajaran mesin yang lebih canggih seperti MiniLM. MiniLM, sebuah model ringan yang dirancang untuk menghasilkan representasi teks dalam bentuk vektor semantik tanpa mengorbankan kualitasnya, telah terbukti efisien dalam meningkatkan hasil pencarian (Bhopale & Tiwari, 2024). Model ini, yang termasuk dalam kategori Sentence Transformers, menghitung skor kesamaan semantik menggunakan cosine similarity antara embedding teks kueri dan dokumen. Hal ini memungkinkan sistem untuk mengidentifikasi dokumen yang relevan berdasarkan hubungan semantik, bukan hanya kecocokan permukaan. Studi juga menunjukkan bahwa MiniLM efektif dalam menangkap sinonim, frasa serupa, dan konteks kalimat yang lebih luas, sehingga meningkatkan relevansi hasil pencarian (Yang et al., 2024). Penggunaan MiniLM dalam sistem pencarian semantik membuka peluang untuk solusi yang lebih efisien, intuitif, dan berorientasi pada pengguna.

c). Metode Hybrid


Penelitian ini mencoba mengkombinasikan antara metode leksikal dan semantik. Langkah pertama menggunakan model leksikal BM25L menghasilkan skor relevansi berdasarkan perhitungan frekuensi kata dan panjang dokumen. Setiap kueri diproses secara terpisah, dan skor relevansi dihitung untuk setiap dokumen di dalam folder. Kemudian dengan model Sentence Transformers digunakan untuk mengubah kalimat kueri dan dokumen menjadi representasi vektor numerik yang mempertimbangkan konteks dan makna kata dalam kalimat. Model ini menggunakan arsitektur transformer seperti all-MiniLM-L6-v2, yang cukup ringan untuk proses pengambilan informasi. Skor kesamaan semantik dihitung menggunakan cosine similarity antara embedding kueri dan dokumen, menghasilkan daftar dokumen yang relevan berdasarkan kesamaan semantik. Kemudian skor dari BM25L dan model semantik digabungkan menggunakan Reciprocal Rank Fusion (RRF). Teknik ini menggabungkan dua peringkat dengan menghitung skor gabungan berdasarkan peringkat dari masing-masing mode (Maryamah et al., 2024):

$$RRF_{score}(d \in D) = \sum_R^r \frac{1}{k + r(d)}$$

Result


1. Analisis Eksplorasi Data

Sebelum membahas performa sistem menggunakan metrik evaluasi *precision* dan *recall*, dilakukan analisis eksplorasi data (EDA) untuk memahami karakteristik dari dataset resep makanan dari situs *EatingWell*, termasuk distribusi kategori masakan, jumlah resep pada setiap kategori, serta analisis lainnya yang dapat memberikan informasi mengenai data.



Gambar 2.1 Barchart Resep Masakan Terbanyak

Barchart di atas merupakan 10 distribusi resep makanan terbanyak yang terdapat di dataset/situs *EatingWell*. Resep yang terbanyak pada situs *EatingWell* merupakan masakan Amerika sebanyak 1301 resep. Diikuti dengan masakan Italia dan Meksiko yang masing-masing sebanyak 61 dan 49 resep. Selanjutnya disusul oleh masakan Asia sebanyak 32 resep, Yunani sebanyak 17 resep, serta masakan Prancis dan India masing-masing sebanyak 11 resep. Kategori dengan jumlah resep paling sedikit adalah masakan Timur Tengah sebanyak 9 resep dan Jepang sebanyak 8 resep. Resep yang masuk dalam lebih dari satu kategori, seperti ['Asian', 'American'], dihitung sebagai entitas tersendiri sesuai kategorinya masing-masing. Hal ini menunjukkan bahwa *EatingWell* lebih direkomendasikan untuk konsumen dengan preferensi masakan Amerika atau kombinasi masakan Amerika dengan kategori lainnya,



Gambar 2.2 Barchart Informasi Tag Resep

Kolom informasi mencakup atribut diet atau label makanan yang memberikan informasi tambahan mengenai detail resep makanan, seperti komposisi bahan, manfaat kesehatan, dan karakteristik diet. Informasi tag tertinggi berada pada *Soy-Free*, *Nut-Free*, *Egg-Free*, dan *Gluten-Free*, menunjukkan fokus besar pada kebutuhan diet khusus atau alergi. Tag seperti

Whole30, *Paleo*, dan *Low Added Sugar* memiliki kemunculan yang lebih sedikit, mengindikasikan popularitas lebih rendah dalam dataset ini.



Gambar 2.3 Wordcloud

Word cloud digunakan untuk melihat kata dengan frekuensi terbanyak. Hasil *wordcloud* untuk ketiga kolom instruksi, deskripsi, serta bahan-bahan dapat dilihat di atas. Pada *word cloud* instruksi kata-kata yang sering muncul seperti *stir, minute, pepper, tender, top, salt*. Pada *word cloud* deskripsi kata-kata yang sering muncul seperti *recipe, easy, make, flavor, chicken, add*. Pada *word cloud* ingredients kata-kata yang sering muncul seperti *teaspoon, ground pepper, olive oil, salt, virgin oil*.

2. Evaluasi Model

Recall mengukur sejauh mana model mampu mengambil dokumen yang relevan dari seluruh dataset, menekankan pada cakupan informasi yang berhasil diambil. Precision, di sisi lain, mengukur tingkat akurasi dokumen yang diambil dengan menghitung rasio dokumen relevan dibandingkan dengan total dokumen yang diambil. Recall yang tinggi menunjukkan kemampuan sistem untuk mengambil informasi secara luas dan menyeluruh, sedangkan precision yang tinggi menunjukkan bahwa dokumen yang diambil mayoritas relevan dan hanya sedikit dokumen yang tidak sesuai.

Precision dan recall dievaluasi pada posisi pengambilan dokumen ke-5, 10, dan 20. Evaluasi dilakukan menggunakan 60 kueri yang terdiri dari kueri pendek dan panjang, di mana setiap kueri memiliki *ground truth* yang dibuat berdasarkan indeks untuk selanjutnya dievaluasi. Untuk model dasar, penelitian dimulai dengan metode pencarian informasi paling sederhana, yaitu berbasis pencocokan kata kunci atau metode leksikal, seperti Jaccard Similarity, TF-IDF, BM25, dan BM25L. Selain itu, penelitian juga mencakup metode berbasis semantik seperti MiniLM, Ontology, Word2Vec dan LSA. Tiga pendekatan hybrid juga dievaluasi. Pendekatan hybrid menggunakan model leksikal sebagai pencari dokumen awal, dan model semantik digunakan untuk menyusun ulang hasil pencarian.

Tabel 4.1 Perbandingan Metrik Performance Terbaik

Model	Method	Evaluation Metrics					
		$p5$	$r5$	$p10$	$r10$	$p20$	$r20$
Lexical	TF-IDF	0.243	0.111	0.240	0.139	0.240	0.191
	BM25L	0.380	0.192	0.335	0.226	0.291	0.262
	BM25	0.303	0.142	0.270	0.171	0.252	0.196

	Jaccard	0.190	0.056	0.178	0.061	0.170	0.068
Semantic	MiniLM	0.300	0.099	0.285	0.134	0.260	0.167
	Ontology	0.316	0.105	0.278	0.127	0.270	0.173
	Word2Vec	0.153	0.014	0.126	0.016	0.125	0.046
	LSA	0.290	0.099	0.241	0.123	0.240	0.156
Hybrid	BM25L & MiniLM	0.370	0.120	0.330	0.150	0.310	0.180
	BM25L & Ontology	0.329	0.113	0.298	0.132	0.274	0.169
	BM25L & Word2Vec	0.321	0.120	0.275	0.130	0.261	0.165

Analisis kami menunjukkan keunggulan pendekatan information retrieval hibrida yang menggabungkan kekuatan model leksikal dan model semantik. Secara khusus, BM25L muncul sebagai model leksikal terbaik, sedangkan MiniLM dan Ontology memberikan performa paling kuat di antara model semantik. Temuan ini menegaskan kemampuan model semantik untuk menemukan dokumen relevan yang sering terlewat oleh pendekatan berbasis leksikal murni, membuka peluang untuk pengembangan metode hibrida yang lebih lanjut.

Tabel di atas merupakan perbandingan performa antar model. Pada posisi *retrieval* teratas (5 dokumen), kombinasi hibrida BM25L & MiniLM menunjukkan precision sebesar 0,370 dan recall sebesar 0,120, melampaui performa BM25L maupun model semantik secara individual. Metode hibrida ini juga menunjukkan konsistensi ketika lebih banyak dokumen terambil dimana pada posisi 20, precision mencapai 0,310 dan recall 0,150, yang menegaskan efektivitasnya dalam memperoleh dokumen relevan di berbagai tingkatan.

Jika dibandingkan dengan metode individual terbaik, pendekatan hibrida menawarkan peningkatan yang signifikan. Secara spesifik, model BM25L & MiniLM meningkatkan recall sekitar 10% dibandingkan BM25L dan 15% dibandingkan MiniLM pada posisi retrieval ke-20. Selain itu, metode ini juga memberikan peningkatan precision sebesar 7,8% dibandingkan model semantik terbaik, menunjukkan kemampuannya dalam menyeimbangkan precision dan recall.

Meskipun model semantik seperti MiniLM unggul dalam tahapan tertentu, performa precision cenderung menurun seiring dengan peningkatan jumlah dokumen yang terambil. Hal ini memperkuat sifat saling melengkapi dari pendekatan hibrida, di mana model leksikal seperti BM25L unggul dalam tahap awal retrieval sedangkan metode semantik melakukan penyempurnaan hasil untuk meningkatkan akurasi. Tabel dibawah merepresentasikan evaluasi model dengan tiga macam pendekatan yaitu *leksikal*, *semantik*, dan *hybrid* dengan mengimplementasikan BM25L dan MiniLM.

Tabel 4.2 Perbandingan Metrik Performance Terbaik

Model	Method	Evaluation Metrics					
		<i>p5</i>	<i>r5</i>	<i>p10</i>	<i>r10</i>	<i>p20</i>	<i>r20</i>
Lexical	BM25L	0.380	0.192	0.335	0.226	0.291	0.262
Semantic	Ontology	0.316	0.105	0.278	0.127	0.270	0.173

Hybrid	BM25 + Ontology	0.329	0.113	0.298	0.132	0.274	0.169
	BM25L + MiniLM	0.370	0.120	0.330	0.150	0.310	0.180

Hasil evaluasi menunjukkan bahwa metode BM25L memiliki performa *precision* yang paling baik, terutama pada tingkat *cutoff* kecil seperti *p5* dan *p10*, dengan nilai *precision* masing-masing sebesar 34% dan 30.8%, sedangkan *recall* pada metode ini mencapai 15% pada *r5* dan meningkat menjadi 18.2% pada *r10*. Hal ini mengindikasikan bahwa BM25L lebih efektif dalam menemukan dokumen relevan pada jumlah terbatas tetapi dinilai kurang optimal dalam menangkap seluruh dokumen relevan yang ada ketika cakupan diperluas.

Metode Ontology menunjukkan *precision* yang lebih rendah dibandingkan BM25L, yaitu 31.6% pada *p5* dan 27.8% pada *p10*, dengan *recall* sebesar 10.5% pada *r5* dan 12.7% pada *r10*. *Precision* dan *recall* metode Ontology tetap stabil ketika cakupan dokumen diperluas hingga 20 dokumen (*p20* = 27%, *r20* = 17%), yang menunjukkan bahwa metode ini mampu menangkap variasi dokumen relevan dengan cukup baik.

Sementara itu, metode *Hybrid* (gabungan BM25L & MiniLM) menunjukkan performa *precision* yang paling baik di antara ketiga metode. *Precision* mencapai 37% pada *p5*, kemudian menurun menjadi 33% pada *p10* dan 31% pada *p20*, menunjukkan adanya penurunan yang cukup stabil ketika jumlah dokumen diperbanyak. Hal ini menunjukkan bahwa metode Hybrid lebih unggul dalam menghasilkan dokumen relevan pada *cutoff* kecil (*p5*) tetapi performanya sedikit menurun pada cakupan dokumen yang lebih luas. Metode *Hybrid* mampu menggabungkan keunggulan pendekatan leksikal dan semantik untuk memberikan *precision* tertinggi pada top-5 hasil pencarian.

Tabel 4.3 Best Model with Fine-Tuning

Best Model	Evaluation Metrics					
	<i>p5</i>	<i>r5</i>	<i>p10</i>	<i>r10</i>	<i>p20</i>	<i>r20</i>
No Fine-Tuning	0.370	0.120	0.330	0.150	0.310	0.180
With Fine-Tuning	0.378	0.124	0.338	0.157	0.324	0.193

Setelah fine-tuning, *precision* meningkat dari 37% menjadi 37,8% pada *p5*, dari 33% menjadi 33,8% pada *p10*, dan dari 31% menjadi 32,4% pada *p20*. *Recall* juga mengalami peningkatan, dari 12% menjadi 12,4% pada *r5*, dari 15% menjadi 15,7% pada *r10*, dan dari 18% menjadi 19,3% pada *r20*. Performa model setelah ditambahkan fine-tuning menunjukkan adanya peningkatan, meskipun tidak signifikan. Hal ini tetap membuktikan bahwa model dengan fine-tuning lebih efektif dalam mengembalikan dokumen relevan, terutama di posisi awal hasil retrieval, sehingga memberikan hasil yang lebih akurat dan kontekstual

Discussion

Berdasarkan keenam puluh kueri resep panjang dan pendek, evaluasi menunjukkan bahwa metode BM25L memiliki keunggulan dalam hal *precision*, terutama pada tingkat *cutoff* yang lebih kecil seperti *p5* dan *p10*, dengan nilai *precision* masing-masing sebesar 20% dan 19%. Namun, ketika melihat nilai *recall*, terasa jelas kelemahan metode ini. Dengan nilai *recall* yang rendah, hanya mencapai 3% pada *r5* dan meningkat sedikit menjadi 7% pada *r10*, banyak dokumen relevan yang terlewatkan. Hal ini mengindikasikan bahwa BM25L lebih efektif dalam

menemukan dokumen yang sangat relevan dengan kueri pengguna dalam jumlah yang terbatas, tetapi kurang optimal dalam menangkap seluruh dokumen relevan.

Di sisi lain, metode MiniLM yang digunakan menunjukkan performa lebih stabil antara precision dan recall ketika cakupan diperluas hingga 20 dokumen (*p20* dan *r20*). Ini berarti, MiniLM mampu menangkap variasi dokumen relevan dengan lebih baik meskipun precision-nya sedikit lebih rendah dibandingkan BM25L. Penelitian oleh Agrawal et al. (2022) menunjukkan bahwa model bahasa besar (Large Language Models) memiliki kemampuan unggul dalam memahami konteks semantik, yang membuat mereka lebih efektif dalam tugas-tugas retrieval yang kompleks..

Metode Hybrid yang menggabungkan BM25L dan MiniLM menunjukkan peningkatan performa yang signifikan dibandingkan metode individual leksikal dan semantik. Hal ini menunjukkan bahwa integrasi antara pendekatan leksikal dan semantik terbukti mencapai hasil yang lebih baik tetapi kemungkinan masih dapat ditingkatkan. Salah satu referensi yang relevan adalah penelitian oleh Kim et al. (2022) yang menunjukkan bahwa penggabungan dua model memerlukan teknik *fusion* yang lebih canggih untuk meningkatkan performa pencarian.

Pada metode leksikal, *recall* cenderung tinggi yang berarti mampu mengambil banyak dokumen meskipun dokumen kurang relevan. Leksikal cenderung fokus hanya berdasarkan kata yang sama tanpa memperhatikan konteks yang lebih dalam meskipun sudah memakai model BM25L masih memiliki keterbatasan dalam menangkap konteks semantik yang mendalam, yang sering kali diperlukan dalam pencarian informasi yang kompleks (Khurana et al., 2023) atau lebih cocok untuk kasus pengambilan dokumen sebanyak-banyaknya. Sedangkan pada metode semantik, jika berdasarkan konsistensi performa, metode Ontology paling baik. Hal ini mungkin terjadi karena metode ini memproses sinonim tiap kata di kueri dan mencocokkannya ke dataset sehingga memerlukan *corpus* sendiri yang mendeskripsikan sinonim-sinonim yang sering muncul di dataset.

Selama proses *modeling*, dilakukan beberapa percobaan dan ditemukan kekurangan. Masalah yang muncul berada pada *kueri parsing* dengan boolean yang belum sepenuhnya sempurna dalam mengatasi *negation handling*. Hal ini karena pada dataset terdapat dokumen dengan keterangan seperti "*No Added Sugar*" yang membuat dokumen tersebut bisa lolos jika kueri hanya mencari "*no sugar*" sehingga diperlukan refinemen frasa yang lebih baik (Staudinger et al., 2024). Hal ini kemungkinan besar menjadi penyebab nilai evaluasi bisa ditingkatkan.

Nilai presisi dan recall top-k yang rendah disebabkan oleh banyak kueri yang tidak terambil dengan baik, jika dilihat presisi dan recall masing-masing kueri ada yang bernilai 0, menunjukkan bahwa kueri tersebut tidak terdeteksi atau tidak menghasilkan dokumen yang relevan. Namun, jika ditelaah per kueri, terdapat kueri yang memiliki nilai presisi dan recall bagus mencapai 80-95%.

Dalam percobaan juga ditemukan bahwa penanganan kueri yang berisikan operasi komparatif seperti 'Sugar less than 150 gram', 'Recipes with calories under 250', dan lain sebagainya tidak bisa ditangani dengan baik karena menyebabkan performa menurun. Hal ini disebabkan karena kueri seperti ini memerlukan kemampuan model untuk memahami hubungan kuantitatif seperti Metode SQL (Structured kueri Language). Selain itu struktur data yang menyimpan informasi angka dalam bentuk teks dan model tidak bisa melakukan perhitungan terhadap angka. Sebagai contoh, dalam penelitian yang dilakukan oleh Gao et al. (2021), sistem pencarian berbasis model bahasa dalam artikel COIL: Revisit Exact Lexical Match in Information Retrieval with Contextualized Inverted List mengungkapkan bahwa meskipun model berbasis konteks dapat meningkatkan pemahaman semantik kueri tetapi mereka tetap kesulitan dalam menangani operasi numerik yang memerlukan perhitungan langsung.

Conclusion

Hasil evaluasi menunjukkan bahwa metode *Hybrid* (gabungan BM25L & MiniLM) memiliki performa terbaik dengan *precision* tertinggi pada *cutoff* kecil (p5), diikuti oleh BM25L yang unggul dalam menemukan dokumen relevan dalam jumlah terbatas, dan Ontology yang stabil pada cakupan dokumen lebih luas. Fine-tuning pada model meningkatkan *precision* dan *recall* meskipun tidak signifikan, menunjukkan bahwa fine-tuning membantu model lebih efektif dalam menghasilkan dokumen relevan, khususnya di posisi awal hasil retrieval.

Keterbatasan model dalam menangkap konteks yang lebih luas dalam keragaman dataset dan representasi diet modern menjadi tantangan utama yang perlu diatasi untuk meningkatkan relevansi dan kualitas sistem pencarian resep. Penggunaan teknik canggih seperti Large Language Models (LLM) dan integrasi pengetahuan gizi dapat membantu mengatasi keterbatasan ini dan meningkatkan kualitas rekomendasi. Langkah-langkah pengembangan lebih lanjut yang melibatkan optimasi metode hybrid, peningkatan keberagaman dataset, serta kolaborasi dengan ahli gizi diharapkan dapat menghasilkan sistem pencarian resep makanan yang lebih efektif, user-friendly, dan bermanfaat bagi pengguna. Dengan dukungan dari penelitian terkini, sistem pencarian resep makanan dapat terus berkembang untuk memenuhi kebutuhan pengguna dengan lebih baik di masa depan.

References

- Agrawal, M., Hegselmann, S., Lang, H., Kim, Y., & Sontag, D. (2022). *Large Language Models are Few-Shot Clinical Information Extractors*. <http://arxiv.org/abs/2205.12689>
- Bhopale, A. P., & Tiwari, A. (2024). Transformer based contextual text representation framework for intelligent information retrieval. *Expert Systems With Applications*, 238, 121629. <https://doi.org/10.1016/j.eswa.2023.121629>
- C, I., G. G, J., & F. U, O. (2020). Implementation of Intelligent Document Retrieval Model Using Neuro-Fuzzy Technology. *International Journal of Engineering Applied Sciences and Technology*, 04(10), 65–74. <https://doi.org/10.33564/ijeast.2020.v04i10.013>
- Chen, M., Jia, X., Gorbonos, E., Hoang, C. T., Yu, X., & Liu, Y. (2020). Eating healthier: Exploring nutrition information for healthier recipe recommendation. *Information Processing & Management*, 57(6), 102051. <https://doi.org/10.1016/j.ipm.2019.05.012>
- Ciampi, M., Pietro, G. De, Masciari, E., & Silvestri, S. (2020). Health Data Information Retrieval For Improved Simulation. *2020 28th Euromicro International Conference on Parallel, Distributed and Network-Based Processing (PDP)*, 364–368. <https://doi.org/10.1109/PDP50117.2020.00062>
- Huy, P. C., Minh, N. Q., Tien, N. D., & Anh, T. T. Q. (2022a). Short-Term Electricity Load Forecasting Based on Temporal Fusion Transformer Model. *IEEE Access*, 10, 106296–106304. <https://doi.org/10.1109/ACCESS.2022.3211941>
- Hongwei, L., Binxin, Q., Zhicheng, H., Junnan, L., Yue, Y., & Guolong, L. (2023). An interpretable data-driven method for degradation prediction of proton exchange membrane fuel cells based on temporal fusion transformer and covariates. *International Journal of Hydrogen Energy*, 48(66), 25958–25971. <https://doi.org/10.1016/j.ijhydene.2023.03.316>

- Khurana, D., Koli, A., Khatter, K., & Singh, S. (2023). Natural language processing: state of the art, current trends and challenges. *Multimedia Tools and Applications*, 82(3), 3713–3744. <https://doi.org/10.1007/s11042-022-13428-4>
- Kim, M.-Y., Rabelo, J., Okeke, K., & Goebel, R. (2022). Legal information retrieval and entailment based on BM25, transformer and semantik thesaurus methods. *The Review of Socionetwork Strategies*, 16(1), 157–174. <https://doi.org/10.1007/s12626-022-00103-1>
- Li, D., Zaki, M. J., & Chen, C.-H. (2021). Nutrition Guided Recipe Search via Pre-trained Recipe Embeddings. 2021 IEEE 37th International Conference on Data Engineering Workshops (ICDEW), 20–23. <https://doi.org/10.1109/ICDEW53142.2021.00011>
- Lien, Y.-C., Zamani, H., & Croft, W. B. (2020). Recipe retrieval with visual kueri of ingredients. Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 1565–1568. <https://doi.org/10.1145/3397271.3401244>
- Liu, Y., Lee, H., Achananuparp, P., Lim, E.-P., Cheng, T.-L., & Lin, S.-D. (2019). Characterizing and predicting repeat food consumption behavior for just-in-time interventions. Proceedings of the 9th International Conference on Digital Public Health, 11–20. <http://dx.doi.org/10.1145/3357729.3357736>
- Maryamah, M., Wilsen, G., Suhaimi, C. T., Septiana, R., Fajar, A., & Solihin, M. I. (2024). Hybrid Information Retrieval with Masked and Permuted Language Modeling (MPNet) and BM25L for Indonesian Drug Data Retrieval. *IEEE*.
- Özen, N., Mu, W., van Asselt, E. D., & Bulk, L. M. van den. (2024, May 1). Extracting chemical food safety hazards from the scientific literature automatically using large language models. arXiv.Org. <https://arxiv.org/abs/2405.15787>
- Palermo, G., Caprioli, C., & Albora, G. (2024, June 21). Food pairing unveiled: Exploring recipe creation dynamics through recommender systems. arXiv.Org. <https://arxiv.org/abs/2406.15533>
- Pallagani, V., Ramamurthy, P., Khandelwal, V., Venkataramanan, R., Lakkaraju, K., Aakur, S. N., & Srivastava, B. (2022, March 31). *A rich recipe representation as plan to support expressive multi modal queries on recipe content and preparation process*. arXiv.Org. <https://arxiv.org/abs/2203.17109>
- Picone, P., Girgenti, A., Buttacavoli, M., & Nuzzo, D. (2024). Enriching the Mediterranean diet could nourish the brain more effectively. <https://doi.org/10.3389/fnut.2024.1489489>
- Santos, J. A. dos, Souza, E., Bastos Filho, C. J. A., Albuquerque, H. O., Vitória, D., Lucena, D. C. G. de, Silva, N., & Carvalho, A. de. (2024). HIRS: A Hybrid Information Retrieval System for Legislative Documents. *Proceedings of the Conference*, 320–331.
- Saxena, S., Sangani, R., Prasad, S., Kumar, S., Athale, M., Awhad, R., & Vaddina, V. (2022). Large-Scale Knowledge Synthesis and Complex Information Retrieval from Biomedical Documents. 2022 IEEE International Conference on Big Data (Big Data), 2364–2369. <https://doi.org/10.1109/BigData55660.2022.10020725>
- Staudinger, M., Kusa, W., Piroi, F., Lipani, A., & Hanbury, A. (2024, December). A Reproducibility and Generalizability Study of Large Language Models for Query Generation. In Proceedings of the 2024 Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region (pp. 186-196).

- Spiro, A., Hill, Z., & Stanner, S. (2024). Meat and the future of sustainable diets—Challenges and opportunities. *Nutrition Bulletin*, 49(572-598). <https://doi.org/10.1111/nbu.12713>
- Varela, P. (2024). Greek consumers' perspectives on sustainable food: A cluster analysis approach. *British Food Journal*. <https://doi.org/10.1108/BFJ-06-2024-0627>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). *Attention Is All You Need*. <http://arxiv.org/abs/1706.03762>
- Walsh, H. S., & Andrade, S. R. (2022). semantik Search With Sentence-BERT for Design Information Retrieval. *Proceedings of the ASME Design Engineering Technical Conferences*, DETC2022-89557, V002T02A066. <https://doi.org/10.1115/DETC2022-89557>
- Wang, C., Liu, X., Yue, Y., Tang, X., Zhang, T., Jiayang, C., Yao, Y., Gao, W., Hu, X., Qi, Z., Wang, Y., Yang, L., Wang, J., Xie, X., Zhang, Z., & Zhang, Y. (2023). Survey on Factuality in Large Language Models: Knowledge, Retrieval and Domain-Specificity. *ACM Computing Surveys*, 1(1). <http://arxiv.org/abs/2310.07521>
- Wang, W., Duan, L., Jiang, H., Jing, P., Song, X., & Nie, L. (2020, December 11). Market2Dish: Health-aware food recommendation. *arXiv.Org*. <https://arxiv.org/abs/2012.06416>
- Xie, J., Hong, Z., Mao, J., Peng, L., Bai, Y., Sheng, J., & Tian, Y. (2024). Moringa oleifera Lam. isothiocyanate inhibits lipid accumulation in high-fat diet mice by promoting lipid metabolism and modulating appetite. *Food Science and Human Wellness*. <https://doi.org/10.26599/FSHW.2024.9250328>
- Yang, E., Jänich, T., Mayfield, J., & Lawrie, D. (2024). Language Fairness in Multilingual Information Retrieval. *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2487–2491. <https://doi.org/10.1145/3626772.3657943>
- Yang, L., Paischer, F., Hassani, K., Li, J., Shao, S., Li, Z. G., He, Y., Feng, X., Noorshams, N., Park, S., Long, B., Nowak, R. D., Gao, X., & Eghbalzadeh, H. (2024). *Unifying generative and dense retrieval for sequential recommendation* (arXiv:2411.18814v1). *arXiv*. <https://doi.org/10.48550/arXiv.2411.18814>
- Yang, G., Liu, K., Chen, X., Zhou, Y., Yu, C., & Lin, H. (2021). CCGIR: Information retrieval-based code comment generation method for smart contracts. *Journal of Software: Evolution and Process*, 33(12), e2344. <https://doi.org/10.1002/smr.2344>
- Yang, Z., Khatibi, E., Nagesh, N., Abbasian, M., Azimi, I., Jain, R., & Rahmani, A. M. (2024, February 18). ChatDiet: Empowering personalized nutrition-oriented food recommender chatbots through an llm-augmented framework. *arXiv.Org*. <https://arxiv.org/abs/2403.00781>
- Yu, C. (2023). A fast retrieval method of drug information based on multidimensional data analysis. *Soft Computing*, 27(13), 9019–9029. <https://doi.org/10.1007/s00500-023-08161-5>
- Zan, Z., Li, L., Liu, J., & Zhou, D. (2020). Sentence-based and noise-robust cross-modal retrieval on cooking recipes and food images. *Proceedings of the 2020 International Conference on Multimedia Retrieval*, 117–125. <https://doi.org/10.1145/3372278.3390681>
- Zhang, Y., Zhou, X., Meng, Q., Zhu, F., Xu, Y., Shen, Z., & Cui, L. (2024, June 27). Multi-modal Food Recommendation using Clustering and Self-supervised Learning. *arXiv.Org*. <https://arxiv.org/abs/2406.18962>
- Zheng, P., Zhou, H., Liu, J., & Nakanishi, Y. (2023). Interpretable building energy consumption forecasting using spectral clustering algorithm and temporal fusion transformers architecture. *Applied Energy*, 349, 121607. <https://doi.org/10.1016/j.apenergy.2023.121607>

Zhu, Y., Yuan, H., Wang, S., Liu, J., Liu, W., Deng, C., Chen, H., Liu, Z., Dou, Z., & Wen, J.-R.
(2023). *Large Language Models for Information Retrieval: A Survey*.
<http://arxiv.org/abs/2308.07107>